

NeuroSnap Vision

Sistem inteligent pentru analiza alimentației din imagini și generarea de
recomandări nutriționale adaptive

Student: Chindriș Andrei

Facultatea de informatică

2026

Rezumat

Obiceiurile alimentare reflectă mai mult decât simple alegeri zilnice: ele influențează nivelul de energie, echilibrul organismului și calitatea vieții. Totuși, pentru mulți oameni, urmărirea meselor și înțelegerea impactului nutrițional al acestora rămân procese dificile și greu de menținut constant. NeuroSnap Vision propune o aplicație web inteligentă care transformă o imagine a mesei într-o analiză nutrițională clară, rapidă și ușor de folosit.

Sistemul utilizează un model de Machine Learning bazat pe EfficientNetB1, antrenat pe datasetul Food-101, pentru recunoașterea alimentelor din imagini. Informațiile obținute sunt integrate într-un jurnal alimentar digital, unde aplicația calculează valori nutriționale, Healthy Score și Brain Nutrition Score. Astfel, aplicația nu se limitează la identificarea alimentelor, ci oferă o imagine mai amplă asupra relației dintre alimentație, obiceiuri zilnice și bunăstare cognitivă.

Pentru generarea recomandărilor personalizate, proiectul integrează o componentă de Reinforcement Learning multi-agent, capabilă să analizeze diferite aspecte ale comportamentului alimentar, precum aportul de proteine, echilibrul caloric, consumul de grăsimi, orele meselor și consistența pe termen scurt. Scopul proiectului este de a demonstra modul în care metode moderne de Inteligență Artificială pot fi utilizate într-o aplicație practică, orientată către conștientizarea și îmbunătățirea obiceiurilor alimentare.

Cuprins

1	Introducere	3
1.1	Contextul proiectului	3
1.2	Problema abordată	3
1.3	Obiectivele aplicației	3
1.4	Contribuția proprie	4
2	State of the Art	5
2.1	Aplicații existente de nutriție	5
2.2	Recunoașterea alimentelor din imagini	5
2.3	Estimarea valorilor nutriționale	5
2.4	Reinforcement Learning în recomandări	6
2.5	Limitările soluțiilor existente	6
3	Arhitectura aplicației	7
4	Tehnologii utilizate	8
4.1	Next.js	8
4.2	FastAPI	8
4.3	TensorFlow și Keras	8
4.4	Food-101	8
4.5	Scikit-learn, Pandas și NumPy	8
4.6	Pillow și Uvicorn	9
4.7	Vercel și Hugging Face Spaces	9
5	Componenta Machine Learning	10
5.1	Datasetul Food-101	10
5.2	Preprocesarea imaginilor	10
5.3	Arhitectura EfficientNetB1	10
5.4	Transfer learning și fine-tuning	10
5.5	Evaluarea modelului	11
5.6	Integrarea modelului în aplicație	11

6	Componenta Reinforcement Learning	12
6.1	Definirea problemei RL	12
6.2	Stări, acțiuni și recompense	12
6.3	Agenții RL utilizați	12
6.4	Coordinator Agent	13
6.5	Antrenarea agenților	13
6.6	Integrarea recomandărilor în aplicație	13
7	Module nutriționale avansate	15
7.1	Healthy Score	15
7.2	Brain Nutrition Score	15
7.3	Meal Journal și analiza pe zile	16
7.4	Recomandări personalizate	16
8	Rezultate și interpretare	17
8.1	Rezultatele modelului Machine Learning	17
8.2	Rezultatele componentei Reinforcement Learning	17
8.3	Rezultatele scorurilor nutriționale	17
8.4	Interpretare generală	17
9	Manual de utilizare	18
9.1	Interfața aplicației	18
9.2	Accesarea aplicației online	18
9.3	Instalarea aplicației	19
9.4	Pornirea backend-ului	19
9.5	Pornirea frontend-ului	19
9.6	Scanarea unei mese	19
9.7	Salvarea în jurnal	19
9.8	Vizualizarea rapoartelor și recomandărilor	20
10	Concluzii	21
10.1	Concluzii generale	21
10.2	Limitări	21
10.3	Direcții viitoare	21

Capitolul 1

Introducere

1.1 Contextul proiectului

În prezent, alimentația reprezintă un element important al stilului de viață, influențând nu doar greutatea corporală, ci și energia, concentrarea, starea generală și calitatea obiceiurilor zilnice. Totuși, pentru multe persoane, urmărirea meselor și înțelegerea impactului nutrițional al acestora rămân niște procese dificile.

O alimentație echilibrată începe cu alegeri mici, repetate zilnic. Prin analizarea meselor și a tiparelor alimentare, aplicația ajută utilizatorul să înțeleagă mai bine ce consumă, să observe dezechilibrele și să facă pași concreți spre un stil de viață mai sănătos.

1.2 Problema abordată

În viața de zi cu zi, mesele sunt adesea alese pe grabă, fără ca utilizatorul să aibă o imagine clară asupra calității alimentației. Deși multe aplicații pot afișa calorii și valori nutriționale, acestea nu evidențiază întotdeauna obiceiurile care se repetă în timp, precum mesele dezechilibrate, consumul ridicat de grăsimi sau lipsa de consecvență. Astfel, utilizatorul poate cunoaște valori numerice, dar nu înțelege mereu ce comportamente ar trebui îmbunătățite.

1.3 Obiectivele aplicației

Obiectivele aplicației sunt:

- identificarea alimentelor direct din imagini, folosind un model de Machine Learning;
- estimarea valorilor nutriționale pentru mesele scanate;
- organizarea meselor într-un jurnal alimentar digital;

- evidențierea evoluției zilnice și săptămânale prin rapoarte;
- calcularea unor scoruri precum Healthy Score și Brain Nutrition Score;
- generarea de recomandări personalizate printr-un sistem multi-agent de Reinforcement Learning.

1.4 Contribuția proprie

Contribuția proprie constă în proiectarea și integrarea completă a unei aplicații inteligente pentru analiză alimentară. Aceasta include antrenarea modelului de recunoaștere a alimentelor, dezvoltarea backend-ului, implementarea jurnalului alimentar, realizarea sistemului multi-agent de recomandări și construirea interfeței web optimizate pentru utilizare mobilă.

Capitolul 2

State of the Art

2.1 Aplicații existente de nutriție

Aplicațiile moderne de nutriție nu se mai limitează la jurnale alimentare manuale. Soluții precum MyFitnessPal sau SnapCalorie includ deja scanarea meselor, recunoaștere vizuală, estimarea macronutrienților și recomandări personalizate. MyFitnessPal folosește Machine Learning și Computer Vision pentru Meal Scan, iar SnapCalorie promovează estimarea caloriilor și porțiilor din fotografii. [9, 10]

2.2 Recunoașterea alimentelor din imagini

Recunoașterea alimentelor din imagini este o direcție importantă în aplicațiile moderne de nutriție. Modelele bazate pe rețele neuronale pot identifica alimente pe baza texturii, formei și culorii, iar transfer learning-ul permite adaptarea unor modele preantrenate la dataseturi alimentare. În acest proiect, EfficientNetB1 este adaptat pe datasetul Food-101 pentru recunoașterea alimentelor, iar sistemul returnează primele trei predicții probabile pentru a reduce riscul unei clasificări greșite.

2.3 Estimarea valorilor nutriționale

Estimarea nutrițională automată este mai dificilă decât clasificarea alimentului, deoarece o imagine nu oferă întotdeauna gramajul, porția exactă sau ingredientele ascunse. Din acest motiv, multe aplicații combină recunoașterea vizuală cu baze de date nutriționale și estimări ale porției. În proiect, valorile nutriționale sunt calculate pe baza alimentului detectat și a porției selectate, oferind o estimare practică pentru jurnalul alimentar.

2.4 Reinforcement Learning în recomandări

Reinforcement Learning permite unui sistem să aleagă recomandări pe baza unei stări observate și să își îmbunătățească deciziile prin recompense. În contextul nutriției, starea poate include aportul de proteine, kaloriile, grăsimile, orele meselor și consistența obiceiurilor. Proiectul folosește o abordare multi-agent, în care agenți specializați analizează aspecte diferite ale alimentației, iar un coordonator selectează recomandarea finală.

2.5 Limitările soluțiilor existente

Deși aplicațiile actuale sunt tot mai avansate, există încă limitări importante: estimarea porțiilor rămâne dificilă, predicțiile pot fi influențate de calitatea imaginii, iar multe soluții oferă valori nutriționale fără o analiză clară a tiparelor utilizatorului. Proiectul propus se diferențiază prin combinarea recunoașterii vizuale cu jurnal alimentar, scoruri nutriționale, Brain Nutrition Score și recomandări adaptive generate printr-un sistem multi-agent.

Modular Client-Server Architecture




Figura prezintă modul în care sunt conectate principalele componente ale aplicației. Utilizatorul folosește interfața Next.js pentru scanarea meselor, consultarea jurnalului și vizualizarea rapoartelor, iar cererile sunt trimise către backend-ul FastAPI prin endpoint-uri dedicate.

Backend-ul coordonează modulele aplicației: predicția alimentelor, analiza nutrițională, scorurile și recomandările. Partea de inteligență artificială include modelul EfficientNetB1 pentru recunoașterea alimentelor, sistemul multi-agent de Reinforcement Learning și modulele de evaluare nutrițională. Datele salvate în jurnal sunt folosite ulterior pentru rapoarte și recomandări personalizate.

Capitolul 4

Tehnologii utilizate

4.1 Next.js

Next.js a fost utilizat pentru dezvoltarea frontend-ului aplicației, oferind o interfață modernă, rapidă și optimizată pentru utilizare pe telefon.

4.2 FastAPI

FastAPI a fost utilizat pentru dezvoltarea backend-ului, unde sunt gestionate predicțiile alimentare, scorurile nutriționale și recomandările generate de agenții RL.

4.3 TensorFlow și Keras

TensorFlow și Keras au fost folosite pentru antrenarea și integrarea modelului EfficientNetB1, responsabil de recunoașterea alimentelor din imagini.

4.4 Food-101

Food-101 este datasetul folosit pentru antrenarea modelului de clasificare alimentară, conținând 101 clase de preparate.

4.5 Scikit-learn, Pandas și NumPy

Aceste biblioteci au fost utilizate pentru prelucrarea datelor, calcule numerice și componentele suplimentare de analiză nutrițională.

4.6 Pillow și Uvicorn

Pillow este folosit pentru procesarea imaginilor, iar Uvicorn pentru rularea serverului FastAPI.

4.7 Vercel și Hugging Face Spaces

Frontend-ul este publicat pe Vercel, iar backend-ul pe Hugging Face Spaces, separând interfața aplicației de serviciile AI.

Capitolul 5

Componenta Machine Learning

5.1 Datasetul Food-101

Pentru antrenarea modelului a fost utilizat datasetul Food-101, care conține 101 clase de preparate alimentare. Acesta oferă imagini variate pentru fiecare clasă, fiind potrivit pentru dezvoltarea unui model de recunoaștere a alimentelor din imagini.

5.2 Preprocesarea imaginilor

Imaginile au fost redimensionate la dimensiunea de 240x240 pixeli, compatibilă cu arhitectura EfficientNetB1. De asemenea, imaginile au fost convertite într-un format numeric potrivit pentru model și preprocesate folosind funcțiile specifice arhitecturii EfficientNet.

5.3 Arhitectura EfficientNetB1

Pentru clasificarea alimentelor a fost utilizată arhitectura EfficientNetB1, un model de rețea neuronală convoluțională eficient pentru clasificarea imaginilor. Modelul a fost folosit prin transfer learning, pornind de la ponderi preantrenate și adaptându-l ulterior pentru clasele din Food-101.

5.4 Transfer learning și fine-tuning

Procesul de antrenare a fost realizat în două etape. În prima etapă, baza modelului a fost înghețată, iar antrenarea s-a concentrat pe stratul final de clasificare. În a doua etapă, o parte dintre straturile modelului au fost deblocate pentru fine-tuning, astfel încât modelul să se adapteze mai bine la imaginile alimentare.

5.5 Evaluarea modelului

Modelul a fost evaluat folosind mai multe metrici: accuracy, top-3 accuracy și top-5 accuracy. Aceste metrici sunt utile deoarece, în aplicație, utilizatorului i se afișează cele mai probabile trei predicții, nu doar prima clasă returnată de model.




Figura 5.1: Rezumatul arhitecturii, procesul de antrenare și evaluarea modelului EfficientNetB1.

5.6 Integrarea modelului în aplicație

Modelul antrenat este salvat și încărcat în backend-ul FastAPI. Atunci când utilizatorul încarcă o imagine, backend-ul o preprocesează, rulează predicția și returnează primele trei clase alimentare împreună cu nivelul de încredere și valorile nutriționale asociate.

Capitolul 6

Componenta Reinforcement Learning

6.1 Definirea problemei RL

Componenta de Reinforcement Learning are rolul de a transforma datele din jurnalul alimentar în recomandări personalizate. În loc să ofere sfaturi generale, sistemul analizează starea curentă a utilizatorului și alege recomandarea considerată cea mai utilă pentru îmbunătățirea comportamentului alimentar.

6.2 Stări, acțiuni și recompense

În cadrul sistemului, starea descrie situația nutrițională a utilizatorului, cum ar fi aportul scăzut de proteine, excesul de calorii, consumul ridicat de grăsimi, mesele târzii sau lipsa de consecvență. Acțiunile reprezintă recomandările posibile, de exemplu creșterea aportului de proteine, reducerea grăsimilor sau mutarea ultimei mese mai devreme.

Recompensa este folosită pentru a indica dacă o acțiune este potrivită pentru o anumită stare. Astfel, agentul învață că anumite recomandări sunt mai utile în anumite situații.

6.3 Agenții RL utilizați

Sistemul utilizează o arhitectură multi-agent, în care fiecare agent analizează o problemă nutrițională specifică:

- **Protein Agent** – analizează aportul de proteine;
- **Calorie Agent** – analizează echilibrul caloric;
- **Meal Timing Agent** – analizează mesele consumate la ore târzii;
- **Fat Balance Agent** – analizează aportul de grăsimi;

- **Consistency Agent** – analizează consecvența utilizatorului pe mai multe zile.

Această separare permite sistemului să trateze diferite aspecte ale alimentației independent, înainte de alegerea recomandării finale.

6.4 Coordinator Agent

Coordinator Agent are rolul de a centraliza rezultatele obținute de agenții specializați. Fiecare agent returnează o stare, o acțiune recomandată și o prioritate. Pe baza acestor priorități, coordonatorul selectează problema cea mai importantă și generează recomandarea finală pentru utilizator.

De exemplu, dacă utilizatorul are în același timp un aport foarte scăzut de proteine și câteva mese târzii, sistemul poate acorda prioritate problemei cu impact mai mare asupra obiectivelor nutriționale.

```
test_user = {
    "calories": 1800,
    "target_calories": 2400,
    "protein": 55,
    "target_protein": 140,
    "fats": 85,
    "target_fats": 70,
    "late_meals_count": 4,
    "days_on_target": 2
}

result = coordinator_recommendation(test_user)

result

...
{'selected_agent': 'protein_agent',
 'state': 'very_low_protein',
 'action': 'increase_protein',
 'recommendation': 'Increase your protein intake. Add foods like eggs, chicken, Greek yogurt, tuna, or cottage cheese.',
 'all_agents': {'protein_agent': {'state': 'very_low_protein',
                                   'action': 'increase_protein',
                                   'priority': 5},
                 'calorie_agent': {'state': 'normal_calories',
                                   'action': 'maintain',
                                   'priority': 1},
                 'timing_agent': {'state': 'late_meals',
                                   'action': 'eat_earlier',
                                   'priority': 4},
                 'fat_agent': {'state': 'high_fats', 'action': 'reduce_fats', 'priority': 4},
                 'consistency_agent': {'state': 'inconsistent',
                                       'action': 'improve_consistency',
                                       'priority': 4}}}
```

Figura 6.1: Exemplu de test pentru coordonarea agenților RL și selecția recomandării finale.

6.5 Antrenarea agenților

Agenții au fost antrenați folosind Q-Learning pe scenarii nutriționale simulate. Pentru fiecare agent au fost definite stări, acțiuni și reguli de recompensă specifice. În timpul antrenării, agentul alege acțiuni, primește recompense și actualizează o tabelă Q, care reține cât de potrivită este fiecare acțiune pentru fiecare stare.

6.6 Integrarea recomandărilor în aplicație

Recomandările sunt generate în backend prin endpoint-ul `/recommendation`. Frontend-ul trimite date precum totalul de calorii, proteine, grăsimi, numărul meselor târzii și

consecvența utilizatorului, iar backend-ul returnează agentul selectat, starea detectată, acțiunea recomandată și mesajul final.

Astfel, componenta RL devine partea care transformă datele colectate din jurnal într-o recomandare concretă și ușor de înțeles pentru utilizator.

Capitolul 7

Module nutriționale avansate

7.1 Healthy Score

Healthy Score oferă o evaluare rapidă a calității alimentației pe baza datelor din jurnal. Scorul ia în considerare obiectivele nutriționale, aportul de proteine și grăsimi, orele meselor și consecvența utilizatorului.

7.2 Brain Nutrition Score

Brain Nutrition Score este un scor nutrițional inspirat de principiile dietei MIND. Acesta analizează mesele în funcție de categorii alimentare relevante, precum legume, pește, carne roșie, dulciuri sau alimente prăjite. Scorul are un rol educațional și nu oferă diagnostic medical.




Figura 7.1: Matricea de confuzie pentru clasificarea tiparelor MIND utilizate în Brain Nutrition Score.

7.3 Meal Journal și analiza pe zile

Jurnalul alimentar stochează mesele salvate, porția, valorile nutriționale și ora consumului. Aceste date permit calcularea totalurilor zilnice și identificarea unor tipare alimentare.

7.4 Recomandări personalizate

Recomandările sunt generate prin combinarea scorurilor nutriționale cu deciziile agenților RL. Astfel, utilizatorul primește sugestii concrete pentru îmbunătățirea obiceiurilor alimentare.

Capitolul 8

Rezultate și interpretare

8.1 Rezultatele modelului Machine Learning

Modelul EfficientNetB1 antrenat pe Food-101 a obținut rezultate bune pentru recunoașterea alimentelor. Evaluarea finală a indicat o acuratețe Top-1 de 77.13%, Top-3 Accuracy de 90.65% și Top-5 Accuracy de 94.31%.

Aceste rezultate susțin folosirea fluxului cu primele trei predicții, deoarece utilizatorul are șanse mari să găsească alimentul corect în lista afișată.

8.2 Rezultatele componentei Reinforcement Learning

Sistemul multi-agent RL a reușit să identifice situații precum aport scăzut de proteine, exces caloric, consum ridicat de grăsimi, mese târzii și lipsă de consecvență. Pe baza acestor stări, aplicația generează recomandări personalizate și ușor de înțeles.

8.3 Rezultatele scorurilor nutriționale

Healthy Score și Scorul de nutriție pentru sănătatea creierului oferă o interpretare rapidă a datelor din jurnal. Aceste scoruri ajută utilizatorul să înțeleagă mai clar calitatea alimentației și zonele care pot fi îmbunătățite.

8.4 Interpretare generală

Rezultatele arată că aplicația este funcțională și poate combina recunoașterea alimentelor, analiza nutrițională și recomandările adaptive într-un flux practic. Principalele limitări rămân estimarea aproximativă a porțiilor și dependența de calitatea imaginilor încărcate.

Capitolul 9


Manual de utilizare

9.1 Interfața aplicației

Interfața aplicației este organizată pentru utilizare rapidă pe telefon, cu ecrane clare pentru configurare, scanare, jurnal și rapoarte.

Primele ecrane prezintă pornirea aplicației, completarea profilului și dashboard-ul principal. Utilizatorul poate vedea rapid kaloriile, macronutrienții, scorul nutrițional și ultima masă adăugată.

În zona de jurnal și scanare, aplicația permite încărcarea unei imagini, afișarea predicțiilor și salvarea mesei. Rapoartele și profilul oferă o imagine de ansamblu asupra progresului, recomandărilor AI și obiectivelor personale.



9.2 Accesarea aplicației online

Aplicația poate fi accesată și în varianta deployată, fără rulare locală. Frontend-ul este publicat pe Vercel, iar backend-ul API este publicat pe Hugging Face Spaces. [11, 12]

- Frontend deployat: `nutri-track-ai-vision.vercel.app`
- Backend deployat: Hugging Face Spaces – `nutritrack-vision-ai-api`

9.3 Instalarea aplicației

Pentru rularea aplicației sunt necesare două componente: frontend-ul realizat în Next.js și backend-ul realizat în FastAPI. Dependențele se instalează separat, în folderele corespunzătoare, folosind comenzile specifice fiecărui mediu.

9.4 Pornirea backend-ului

Backend-ul se pornește din folderul `backend`, după activarea mediului virtual Python:

```
.\venv\Scripts\activate  
python -m uvicorn main:app --reload --host 127.0.0.1 --port 8000
```

După pornire, documentația API poate fi accesată la adresa:

`http://127.0.0.1:8000/docs`

9.5 Pornirea frontend-ului

Frontend-ul se pornește din folderul aplicației Next.js folosind comanda:

```
npm run dev
```

Aplicația poate fi accesată local în browser, de obicei la adresa:

`http://localhost:3000`

9.6 Scanarea unei mese

Utilizatorul poate încărca o imagine cu o masă, iar aplicația trimite imaginea către backend. Modelul de Machine Learning returnează cele mai probabile trei predicții, împreună cu nivelul de încredere și valorile nutriționale estimate.

9.7 Salvarea în jurnal

După afișarea predicțiilor, utilizatorul selectează alimentul corect și îl salvează în jurnal. Masa salvată conține numele alimentului, porția, kaloriile, macronutrienții și momentul adăugării.

9.8 Vizualizarea rapoartelor și recomandărilor

Pe baza meselor salvate, aplicația calculează totaluri nutriționale, scoruri alimentare și recomandări personalizate. Utilizatorul poate vedea evoluția alimentației și sugestiile generate de sistemul multi-agent de Reinforcement Learning.

Capitolul 10

Concluzii

10.1 Concluzii generale

Proiectul demonstrează modul în care metodele de Machine Learning și Reinforcement Learning pot fi integrate într-o aplicație web practică pentru analiza alimentației. Sistemul permite recunoașterea alimentelor din imagini, estimarea valorilor nutriționale, salvarea meselor într-un jurnal și generarea de recomandări personalizate pe baza comportamentului alimentar.

10.2 Limitări

Principalele limitări sunt legate de estimarea porțiilor și de calitatea imaginilor încărcate. De asemenea, valorile nutriționale sunt aproximative, deoarece pot varia în funcție de ingrediente, mod de preparare și cantitatea reală consumată.

10.3 Direcții viitoare

Direcțiile viitoare includ estimarea automată a porțiilor prin segmentare vizuală, integrarea cu dispozitive wearable pentru date precum pași și calorii arse, extinderea datasetului alimentar și îmbunătățirea recomandărilor prin date reale colectate de la utilizatori.

Bibliografie

- [1] L. Bossard, M. Guillaumin, L. Van Gool, *Food-101 – Mining Discriminative Components with Random Forests*, European Conference on Computer Vision, 2014.
- [2] M. Tan, Q. V. Le, *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*, International Conference on Machine Learning, 2019.
- [3] C. J. C. H. Watkins, P. Dayan, *Q-learning*, Machine Learning, 1992.
- [4] M. C. Morris et al., *MIND diet associated with reduced incidence of Alzheimer’s disease*, Alzheimer’s & Dementia, 2015.
- [5] TensorFlow, *TensorFlow Documentation*, Disponibil online: <https://www.tensorflow.org/>
- [6] Keras, *Keras Documentation*, Disponibil online: <https://keras.io/>
- [7] FastAPI, *FastAPI Documentation*, Disponibil online: <https://fastapi.tiangolo.com/>
- [8] Vercel, *Next.js Documentation*, Disponibil online: <https://nextjs.org/docs>
- [9] MyFitnessPal, *Meal Scan FAQ*, Disponibil online: <https://support.myfitnesspal.com/hc/en-us/articles/360045761612-Meal-Scan-FAQ>
- [10] SnapCalorie, *AI Calorie Counter and Meal Scan Features*, Disponibil online: <https://www.snapcalorie.com/>
- [11] Chindriș Andrei, *NeuroSnap Vision – aplicația frontend deployată*, Disponibil online: nutri-track-ai-vision.vercel.app
- [12] Chindriș Andrei, *NeuroSnap Vision – backend API deployat*, Disponibil online: Hugging Face Spaces – [nutritrack-vision-ai-api](https://huggingface.co/spaces/nutritrack-vision-ai-api)
- [13] Hugging Face, *Spaces Documentation*, Disponibil online: <https://huggingface.co/docs/hub/spaces>
- [14] Vercel, *Vercel Documentation*, Disponibil online: <https://vercel.com/docs>